

# Сортировки за линейное время

6 октября 2019 г.

# Понятие сортировки

- ▶ **Сортировка** — это алгоритм для упорядочивания элементов в списке.

# Понятие сортировки

- ▶ **Сортировка** — это алгоритм для упорядочивания элементов в списке.
- ▶ **Время работы.** Минимальное время работы алгоритма на каком-либо наборе.

# Понятие сортировки

- ▶ **Сортировка** — это алгоритм для упорядочивания элементов в списке.
- ▶ **Время работы.** Минимальное время работы алгоритма на каком-либо наборе.
- ▶ **Память.** Параметр сортировки, показывающий, сколько дополнительной памяти требуется алгоритму.

# Понятие сортировки

- ▶ **Сортировка** — это алгоритм для упорядочивания элементов в списке.
- ▶ **Время работы.** Минимальное время работы алгоритма на каком-либо наборе.
- ▶ **Память.** Параметр сортировки, показывающий, сколько дополнительной памяти требуется алгоритму.
- ▶ **Устойчивость.** Устойчивой сортировкой называется сортировка, не меняющая порядка объектов с одинаковыми значениями.

# Понятие сложности алгоритма

# Понятие сложности алгоритма

- ▶ Под сложностью алгоритма понимается зависимость объёма работы, от размера входных данных.

# Понятие сложности алгоритма

- ▶ Под сложностью алгоритма понимается зависимость объёма работы, от размера входных данных.
- ▶ фраза «сложность алгоритма есть  $O(f(n))$ » означает, что с увеличением параметра  $n$ , характеризующего количество входной информации алгоритма, время работы алгоритма будет возрастать не быстрее, чем некоторая константа, умноженная на  $f(n)$ .




# Понятие сложности алгоритма

- ▶ Под сложностью алгоритма понимается зависимость объёма работы, от размера входных данных.
- ▶ фраза «сложность алгоритма есть  $O(f(n))$ » означает, что с увеличением параметра  $n$ , характеризующего количество входной информации алгоритма, время работы алгоритма будет возрастать не быстрее, чем некоторая константа, умноженная на  $f(n)$ .
- ▶  $O()$  исключает коэффициенты и члены меньшего порядка.

# Понятие сложности алгоритма

- ▶ Под сложностью алгоритма понимается зависимость объёма работы, от размера входных данных.
- ▶ фраза «сложность алгоритма есть  $O(f(n))$ » означает, что с увеличением параметра  $n$ , характеризующего количество входной информации алгоритма, время работы алгоритма будет возрастать не быстрее, чем некоторая константа, умноженная на  $f(n)$ .
- ▶  $O()$  исключает коэффициенты и члены меньшего порядка.
- ▶ Говорят, что алгоритм работает за линейное время, или  $O(n)$ , если его сложность равна  $O(n)$ . Неформально, это означает, что для достаточно большого размера входных данных время работы увеличивается линейно от размера входа.

# Понятие сложности алгоритма



# Мотивация

# Мотивация

- ▶ Ускорение обработки данных.

# Мотивация

- ▶ Ускорение обработки данных.
- ▶ Упрощение обработки данных.

# Мотивация

- ▶ Ускорение обработки данных.
- ▶ Упрощение обработки данных.
- ▶ Зачем столько разных алгоритмов сортировки?

# Мотивация

- ▶ Ускорение обработки данных.
- ▶ Упрощение обработки данных.
- ▶ Зачем столько разных алгоритмов сортировки?



# Counting Sort

# Counting Sort

- ▶ Идея алгоритма заключается в следующем: сначала создается вспомогательный массив, равный длине исходного массива, поданного на сортировку. Последовательно для всех элементов исходного массива выполняется проход, цель которого определить, сколько раз каждый элемент встречается в исходном массиве. Эти данные заносятся во вспомогательный массив, для  $i$  элемента вспомогательного массива  $B$  номер  $i$  записывается в исходный массив  $B[i]$  раз.

# Counting Sort

- ▶ Идея алгоритма заключается в следующем: сначала создается вспомогательный массив, равный длине исходного массива, поданного на сортировку. Последовательно для всех элементов исходного массива выполняется проход, цель которого определить, сколько раз каждый элемент встречается в исходном массиве. Эти данные заносятся во вспомогательный массив, для  $i$  элемента вспомогательного массива  $B$  номер  $i$  записывается в исходный массив  $B[i]$  раз.
- ▶ Главный недостаток алгоритма - работает лишь для целых положительных чисел.

## Утверждение

*Алгоритм работает за  $O(n+k)$*

- ▶ Counting sort

```
for i in range (len(a)):
    A[a[i]]=A[a[i]]+1
for i in range(len(A)):
    while (A[i]>0):
        a[j]=i
        A[i]-=1
        j+=1
```

# Radix Sort

# Radix Sort

- ▶ Алгоритм состоит в последовательной сортировке объектов какой-либо устойчивой сортировкой по каждому разряду, в порядке от младшего разряда к старшему, после чего последовательности будут расположены в требуемом порядке.

# Radix Sort

- ▶ Алгоритм состоит в последовательной сортировке объектов какой-либо устойчивой сортировкой по каждому разряду, в порядке от младшего разряда к старшему, после чего последовательности будут расположены в требуемом порядке.
- ▶ Наиболее часто в качестве устойчивой сортировки применяют сортировку подсчетом.


## Утверждение

*Алгоритм работает за  $O(n+k)$*

Counting sort

# Radix Sort

## ▶ Пример Поразрядной сортировки





```
length = len(str(max(A)))
lente = len(A)
for i in range(length):
    B = [[] for k in range(lente)]
    for j in range(len(A)):
        n = A[j] // 10**i % 10
        B[n].append(A[j])
    A = []
    for k in range(lente):
        A = A + B[k]
```

# Insertion Sort

# Insertion Sort

- ▶ На каждом шаге алгоритма мы выбираем один из элементов входных данных и вставляем его на нужную позицию в уже отсортированной части массива, до тех пор пока весь набор входных данных не будет отсортирован. Метод выбора очередного элемента из исходного массива произволен, однако обычно (и с целью получения устойчивого алгоритма сортировки), элементы вставляются по порядку их появления во входном массиве.

# Insertion Sort

- ▶ На каждом шаге алгоритма мы выбираем один из элементов входных данных и вставляем его на нужную позицию в уже отсортированной части массива, до тех пор пока весь набор входных данных не будет отсортирован. Метод выбора очередного элемента из исходного массива произволен, однако обычно (и с целью получения устойчивого алгоритма сортировки), элементы вставляются по порядку их появления во входном массиве.  
Insertion sort

```
for i in range(len(data)):
    j = i - 1
    key = data[i]
    while (data[j] > key and j >= 0):
        data[j + 1] = data[j]
        j -= 1
    data[j + 1] = key
```

# Bucket Sort

# Bucket Sort

- ▶ Для карманной сортировки нужно разбить элементы массива входных данных на  $k$  блоков (карманов, корзин). Далее каждый из таких блоков сортируется либо другой сортировкой, либо рекурсивно тем же методом разбиения. После сортировок внутри каждого блока данные записываются в массив в порядке разбиения на блоки. При этом нужно учитывать, что данная сортировка работает только в том случае, если разбиение на блоки производится таким образом, чтобы элементы каждого следующего блока были больше предыдущего.

# Bucket Sort

- ▶ Для карманной сортировки нужно разбить элементы массива входных данных на  $k$  блоков (карманов, корзин). Далее каждый из таких блоков сортируется либо другой сортировкой, либо рекурсивно тем же методом разбиения. После сортировок внутри каждого блока данные записываются в массив в порядке разбиения на блоки. При этом нужно учитывать, что данная сортировка работает только в том случае, если разбиение на блоки производится таким образом, чтобы элементы каждого следующего блока были больше предыдущего.
- ▶ Карманная сортировка сильно деградирует при большом количестве мало отличных элементов (большинство элементов попадёт в одну корзину). Поэтому такой тип сортировки использовать, когда велика вероятность того, что числа редко повторяются (например, последовательность случайных чисел)




# Bucket Sort

- ▶ Для карманной сортировки нужно разбить элементы массива входных данных на  $k$  блоков (карманов, корзин). Далее каждый из таких блоков сортируется либо другой сортировкой, либо рекурсивно тем же методом разбиения. После сортировок внутри каждого блока данные записываются в массив в порядке разбиения на блоки. При этом нужно учитывать, что данная сортировка работает только в том случае, если разбиение на блоки производится таким образом, чтобы элементы каждого следующего блока были больше предыдущего.
- ▶ Карманная сортировка сильно деградирует при большом количестве мало отличных элементов (большинство элементов попадёт в одну корзину). Поэтому такой тип сортировки использовать, когда велика вероятность того, что числа редко повторяются (например, последовательность случайных чисел)

# Bucket Sort

- ▶ Пример сортировки вычёрпыванием
- ▶ Bucket Sort



```
def bucketSort(x):  
    arr = []  
    slot_num = 10  
    for i in range(slot_num):  
        arr.append([])  
  
    for j in x:  
        index_b = int(slot_num * j)  
        arr[index_b].append(j)  
  
    for i in range(slot_num):  
        arr[i] = insertionSort(arr[i])  
    k = 0  
    for i in range(slot_num):  
        for j in range(len(arr[i])):  
            x[k] = arr[i][j]  
            k += 1  
    return x
```

# Bucket Sort

- ▶ Теорема. Алгоритм SortB работает за время  $O(N)$  в среднем, где  $N$  – количество сортируемых элементов. Доказательство. Пусть  $p=1/N$ . Вероятность попадания в один контейнер  $k$  элементов равна  $p^k = (1/N)^k$  (биномиальное распределение). Время работы алгоритма сортировки в одном контейнере равно  $O(k^2)$ , где  $k$  – количество элементов, попавших в  $i$ -ый контейнер. Согласно свойствам биномиального распределения, среднее (математическое ожидание) количество элементов в контейнере равно  $M(k) = \sum_k p k^k = Np = 1$ . Средне-квадратичное отклонение от среднего значения (дисперсия) количества элементов в контейнере равно  $D(k) = \sum_k p k^2 (k - M(k))^2 = \sum_k p k^2 (k-1)^2 = Np(1-p) = 1-1/N$ .  $D(k) = M(k^2) - (M(k))^2$  из чего сразу следует  $M(k^2) = D(k) + (M(k))^2 = 1-1/N$ . Итого, среднее время сортировки одного контейнера равно  $O(1)$ , а среднее время сортировок  $N$  контейнеров равно  $O(N)$ .

# Pancake Sort

- ▶ Алгоритм сортировки с помощью одной операции — переворота элементов последовательности до какого-то индекса (префикса последовательности). Разумеется, разрешены сравнения, при оценке времени работы этого алгоритма оценивается количество переворотов, а не сравнений. Название алгоритма пошло от изначальной задачи отсортировать стопку блинов по возрастанию размера.
- ▶ Pancake sort

## Утверждение

*Алгоритм корректен и работает за линейное время.*

# Pancake Sort

- ▶ Покажем, что любую последовательность можно отсортировать с помощью блинной сортировки. Для этого будет предложен алгоритм, позволяющий отсортировать любой массив, сделав не более  $2n$  операций, где  $n$  — размер массива. Найдём  $\max$  элемент последовательности с номером  $i$  и развернём префикс массива до  $i$ -го элемента. Теперь  $\max$  элемент находится в начале массива. Развернём весь массив, теперь  $\max$  элемент находится в конце массива. Сделаем то же самое рекуррентно для префикса длины  $n-1$ . Переместим второй по возрастанию элемент в конец подотрезка, после чего последние два элемента будут отсортированы, и продолжим для префикса длины  $n-2$ . Таким образом, на каждой итерации мы сделаем две операции, и всего итераций будет не больше  $n$ . Тогда суммарное количество операций не превосходит  $2n$  и любая последовательность может быть отсортирована таким образом.

```
def pancake(data):  
  
    if len(data) > 1:  
        for i in range(len(data) - 1, -1):  
            mxin=data.index(max(data[:i]))  
            if (mxin==(i - 1)):   
                continue  
            data[:mxin+1]=list(reversed(data[:mxin+1]))  
            data[i]=list(reversed(data[i]))  
  
    return data
```

# Литература

- ▶ [wikipedia.org](https://wikipedia.org)
- ▶ Алгоритмы и алгоритмические языки-Староверов, В.М., МГУ им. М.В.Ломоносова, 2018.
- ▶ [neerc.ifmo.ru](https://neerc.ifmo.ru)
- ▶ Алгоритмы: построение и анализ-Книга, Клиффорд Штайн, Рональд Линн Ривест, Томас Кормен, и Чарльз Эрик Лейзерсон.
- ▶ [habr.com](https://habr.com)